ChatGLM2-6B SFT 微调实战

Background

ChatGLM2-6B

ChatGLM2-6B是开源中英双语对话模型 ChatGLM-6B 的第二代版本。

ChatGLM 模型是由清华大学开源的、支持中英双语问答的对话语言模型，并针对中文进行了优化。 该模型基于General Language Model（GLM）架构，具有62 亿参数。结合模型量化技术，用户可以在消费级的 显卡 上进行本地部署（INT4 量化级别下最低只需 6GB 显存） 。

为了方便下游开发者针对自己的应用场景定制模型，同时实现了基于 P-Tuning v2 的高效参数微调方法，INT4 量化级别下最低只需 7GB 显存即可启动微调。

不过，由于 ChatGLM-6B 的规模较小，目前已知其具有相当多的局限性，如事实性/数学逻辑错误，可能生成有害/有偏见内容，较弱的上下文能力，自我认知混乱，以及对英文指示生成与中文指示完全矛盾的内容。

硬件需求

量化等级	最低 GPU 显存（推理）	最低 GPU 显存（高效参数微调）
FP16（无量化）	13 GB	14 GB
INT8	8 GB	9 GB
INT4	6 GB	7 GB

我的硬件参数：Amazon SageMaker平台，主要使用两块 NVIDIA A10-24GB GDDR6训练和部署。

P-Tuning 微调

P-Tuning 是一种对预训练语言模型进行少量参数微调的技术。所谓预训练语言模型，就是指在大规模的语言数据集上训练好的、能够理解自然语言表达并从中学习语言知识的模型。P-Tuning 所做的就是根据具体的任务，对预训练的模型进行微调，让它更好地适应于具体任务。相比于重新训练一个新的模型，微调可以大大节省计算资源，同时也可以获得更好的性能表现。

1. 部署ChatGLM2-6B

1.1 安装环境

1.1.1 配置基础环境

安装pytorch： https://pytorch.org/

cuda：https://developer.nvidia.com/cuda-downloads

使用如下代码验证是否成功安装

```
import torch
torch.cuda.is_available()
print(torch.version.cuda)
```

我使用的python版本为3.10, cuda 版本为12.0，pytorch 版本为 11.7。

注意:python版本不能高于3.10，cuda版本需要和pytorch版本对应，具体信息查看 https://pytorch.org/get-started/previous-versions/

1.1.2 从Github上下载项目文件

首先需要下载Github仓库：

```
git clone https://github.com/THUDM/ChatGLM2-6B
cd ChatGLM2-6B
```

接着使用pip安装依赖：

```
pip install -r requirements.txt
```

1.1.3 下载模型

官方的代码会直接从HuggingFace上下载模型：

```
from transformers import AutoTokenizer, AutoModel>>> tokenizer = AutoTokenizer.from_pretrained("THUDM/chatglm2-6b", trust_remote_code=True)
model = AutoModel.from_pretrained("THUDM/chatglm2-6b", trust_remote_code=True, device='cuda')
```

但是这样做不易于我们管理模型的地址，而且网速较慢的情况下可能会出现下载失败的情况。

我们可以直接从Hugging Face上下载地址：

先安装Git LFS并验证成功：

```
$ git lfs install> Git LFS initialized.
```

接下来在刚刚从Github上clone的文件夹中打开命令行，输入:

```
git clone https://huggingface.co/THUDM/chatglm2-6b
```

就可以下载模型了!

请确认一共有7个model文件，每次加载时都会读取这7个文件。

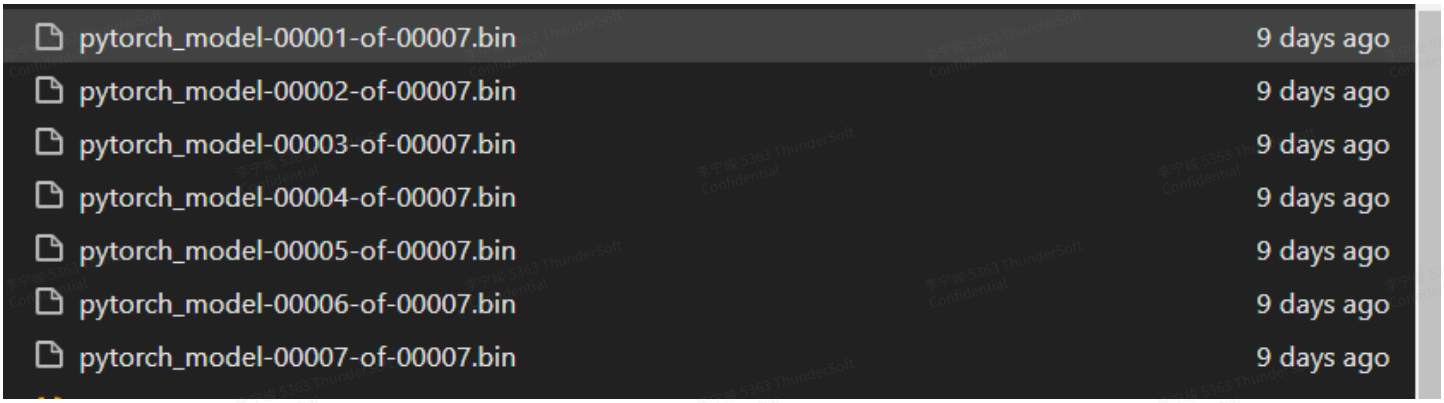

将模型下载到本地之后，将以上代码中的 `THUDM/chatglm2-6b` 替换为你本地的 `chatglm2-6b` 文件夹的路径，即可从本地加载模型。

1.2 部署模型

下载好模型后，我们就可以尝试部署了。可以通过两种方法部署模型。

1.2.1 直接部署

第一种是直接用命令行或者终端部署。将path更改为GLM2文件夹的绝对地址后运行下面的代码：

```
from transformers import AutoTokenizer, AutoModel
import torch

#设置运行的CPU，如果没有多块CPU就填0
DEVICE = "cuda"
DEVICE_ID = "3"
CUDA_DEVICE = f"{DEVICE}:{DEVICE_ID}" if DEVICE_ID else DEVICE

if torch.cuda.is_available():
    torch.cuda.set_device(CUDA_DEVICE)

if __name__ == '__main__':
    #path 更改为GLM2文件夹的绝对地址
    path = "你的文件夹地址"
    from transformers import AutoTokenizer, AutoModel
    tokenizer = AutoTokenizer.from_pretrained(path, trust_remote_code=True)
    model1 = AutoModel.from_pretrained(path, trust_remote_code=True, device=CUDA
    torch.cuda.set_device(CUDA_DEVICE)
    model1.eval()


    response1, history = model1.chat(tokenizer, "你好", history=[])
    print(response1)
    response1, history = model1.chat(tokenizer, "晚上睡不着应该怎么办", history=his
    print(response1)
```

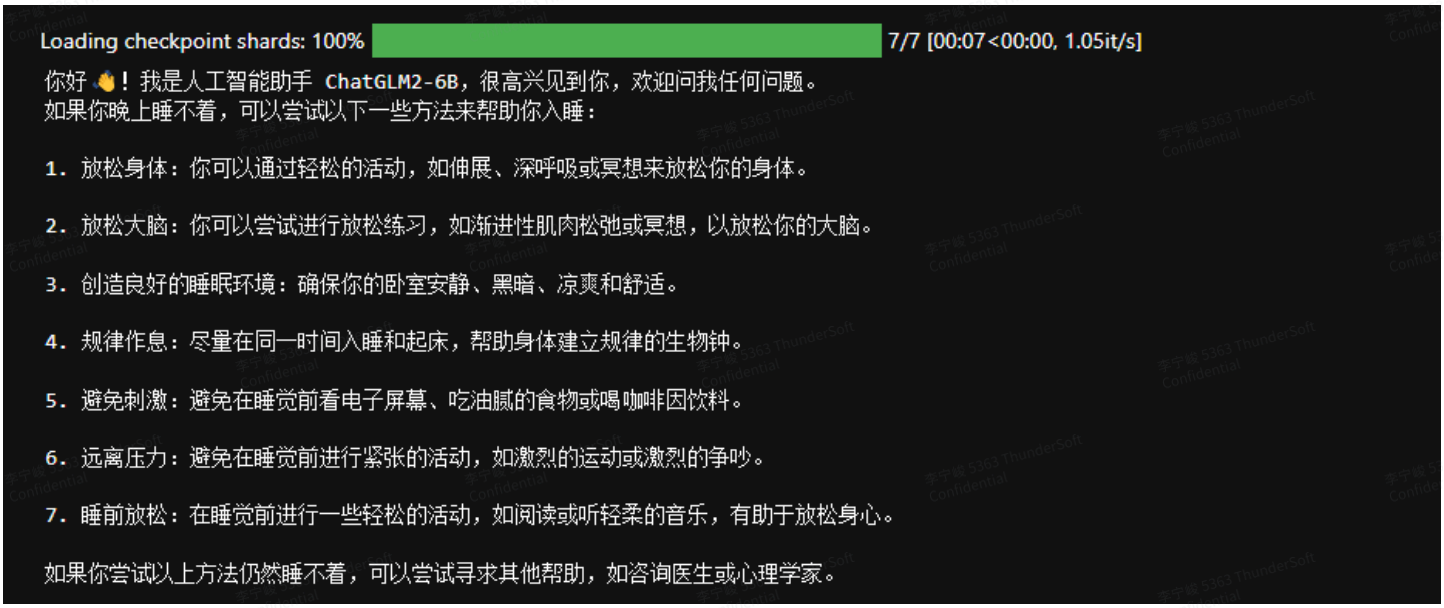

1.2.2 Web Demo部署

第二种部署的方法是运行web demo。打开web_demo.py 文件，用上面同样的代码将path改好：

```python
from transformers import AutoModel, AutoTokenizer
import gradio as gr
import mdtex2html
from utils import load_model_on_gpus

path = "你的文件夹地址"
tokenizer = AutoTokenizer.from_pretrained(path, trust_remote_code=True)
model = AutoModel.from_pretrained(path, trust_remote_code=True).cuda()
model = model.eval()

"""Override Chatbot.postprocess"""


def postprocess(self, y):
    if y is None:
        return []
    for i, (message, response) in enumerate(y):
        y[i] = (
            None if message is None else mdtex2html.convert((message)),
            None if response is None else mdtex2html.convert(response),
        )
    return y
```

注意：服务器端口默认在本地进行，如果在服务器上运行或者需要供其他电脑访问的，需要将最后一行代码

```
demo.queue().launch(share=False, inbrowser=True)
```

改成

```
demo.queue().launch(share=True, inbrowser=True)
```

然后运行web_demo.py 文件，

```
(pytorch_p310) sh-4.2$ python web_demo.py
Loading checkpoint shards: 100%|
| 7/7 [00:05<00:00,
1.19it/s]
/home/ec2-user/SageMaker/chatglm2-6b/web_demo.py:94: GradioDeprecationWarning:
The `style` method is deprecated. Please set these arguments in the
constructor instead.
  user_input = gr.Textbox(show_label=False, placeholder="Input...",
lines=10).style(
#本地访问这个链接
Running on local URL:  http://127.0.0.1:7860
#外网访问这个链接（72小时过期）
Running on public URL: https://88f3b25c8c3f515f77.gradio.live

This share link expires in 72 hours. For free permanent hosting and GPU
upgrades, run `gradio deploy` from Terminal to deploy to Spaces
(https://huggingface.co/spaces)
```

接下来访问对应链接就可以使用Web Demo啦！

1.2.3 量化部署

由于我使用的A10,显存充足，所以上述代码都是运行的无量化模型，大约需要占用13G内存。如果你的显存不足，可以根据需要进行如下更改：

```
path = "/home/ec2-user/SageMaker/chatglm2-6b"
tokenizer = AutoTokenizer.from_pretrained(path, trust_remote_code=True)
model = AutoModel.from_pretrained(path, trust_remote_code=True).cuda()
#想要INT4量化就填4，INT8量化就填8
model = model.quantize(4)
model = model.cuda()
model = model.eval()

response, history = model.chat(tokenizer, "你好", history=[])
```

2. 微调ChatGLM2-6B

2.1 数据集选择

智源研究院COIG-PC数据集 https://huggingface.co/datasets/BAAI/COIG-PC/tree/main/data

COIG-PC 数据集是精心策划、全面的中文任务和数据集合，旨在促进中文自然语言处理 (NLP) 语言模型的微调和优化。该数据集旨在为研究人员和开发人员提供丰富的资源，以提高语言模型处理中文文本的能力，可用于文本生成、信息提取、情感分析、机器翻译等各个领域。

尽管数据集比较全全面，但仍然有许多数据集质量不高，包含大量错误和垃圾内容，经过挑选后我选择了一个质量相对较高的数据集。00169-000-000-tang_poem_continuation。 主要内容是古诗的续

写。包含5万6千多条古诗的续写回答。

原数据集格式：

```
{"instruction": "请根据唐诗的前半部分，补写后半部分。", "input": "度门能不访。冒雪屡西东。已想人如玉。遥怜马似骢。", "output": "乍迷金谷路。稍变上阳宫。还比相思意。纷纷正满空。", "split": null, "task_type": {"major": ["文本生成"], "minor": ["古诗词"]}, "domain": ["文学"], "other": null, "task_name_in_eng": "tang_poem_continuation"}
{"instruction": "请根据唐诗的前半部分，补写后半部分。", "input": "逍遥东城隅。双树寒葱蒨。广庭流华月。高阁凝余霰。杜门非养素。抱疾阻良谶。孰谓无他人。", "output": "思君岁云变。官曹亮先忝。陈躅慙俊彦。岂知晨与夜。相代不相见。缄书问所如。詶藻当芬绚。", "split": null, "task_type": {"major": ["文本生成"], "minor": ["古诗词"]}, "domain": ["文学"], "other": null, "task_name_in_eng": "tang_poem_continuation"}
...
```

直接在HF仓库中搜索下载即可。

2.2 数据集清理

根据GLM内置的代码和示例，训练数据集需要整理为prompt_column 和 response_column 两部分，我将他们命名为：“content” 和 “output”。你也可以自己命名，注意名称一致。

打开ptuning 文件夹 里的 tran.sh 文件，将这两行更改：

```
    --prompt_column content \
    --response_column output \
```

将原数据集清理成这样的格式。将“instruction” 和 “input” 段合并，中间加入“：”，改名为“content”。然后删除“output” 之后的内容。由于我的数据集的原格式将所有字典并列，还需要把所有字典放入一个list中。

清洗之后的数据变成了这样：

```
[
    {
        "content": "请根据唐诗的前半部分，补写后半部分：君归呼。君归兴不孤。",
        "output": "谢朓澄江今夜月。也应忆著此山夫。"
    },
    {
        "content": "请根据唐诗的前半部分，补写后半部分：为郎复典郡。锦帐映朱轮。露冕随龙
        "output": "早霜芦叶变。寒雨石榴新。莫怪谙风土。三年作逐臣。"
    },

```

```
    ...

]
```

如果你想训练多轮对话，官方也提供了方法：

打开ptuning 文件夹 里的 tranchat.sh 文件，将这三行更改：

```
    --prompt_column prompt \
    --response_column response \
    --history_column history \
```

这是官方的多轮对话数据集格式

```
{"prompt": "长城h3风扇不转。继电器好的。保险丝好的传感器新的风扇也新的这是为什么。就是继电
{"prompt": "95", "response": "上下水管温差怎么样啊？空气是不是都排干净了呢？", "histor
{"prompt": "是的。上下水管都好的", "response": "那就要检查线路了，一般风扇继电器是由电脑
```

2.3 数据集和训练集的选择

我选择将训练集打乱，从中取出一半,一共2万4千条当做训练集，再取出剩下的一半中的2000条做验证集。分成 train.json 和 test.json 两个文件。

由于生成唐诗的任务相对比较特殊，验证集仅用来判断在遇到训练数据集中没有出现中过的唐诗时，模型能否能够生成合理的回答。模型在遇到唐诗时，会自动编写下文，而不会从数据库中寻找原文，所以对验证集进行准确度的分析是没有意义的。

2.4 配置训练参数

需要更改GLM2-6B文件中的tran.sh脚本。这是我训练使用的参数：

```
PRE_SEQ_LEN=128
LR=2e-2

#调整使用的GPU数量和编号
NUM_GPUS=2
export CUDA_VISIBLE_DEVICES=2,3

torchrun --standalone --nnodes=1 --nproc-per-node=$NUM_GPUS main.py \
    --do_train \
    --train_file train.json \
    --validation_file train.json \
```

```
    --preprocessing_num_workers 10 \
    --prompt_column content \
    --response_column output \
    --overwrite_cache \
    --model_name_or_path /home/ec2-user/SageMaker/chatglm2-6b \
    --output_dir output/adgen-chatglm2-6b-pt5-$PRE_SEQ_LEN-$LR \
    --overwrite_output_dir \
    --max_source_length 64 \
    --max_target_length 128 \
    --per_device_train_batch_size 16 \
    --per_device_eval_batch_size 1 \
    --gradient_accumulation_steps 1 \
    --predict_with_generate \
    --max_steps 200 \
    --logging_steps 10 \
    --save_steps 25 \
    --learning_rate $LR \
    --pre_seq_len $PRE_SEQ_LEN \

    #进行量化处理
    --quantization_bit 4 \
```

修改 `train.sh` 中的 `train_file`、`validation_file` 和 `test_file` 为你自己的 JSON 格式数据集路径，并将 `prompt_column` 和 `response_column` 改为 JSON 文件中输入文本和输出文本对应的 KEY。可能还需要增大 `max_source_length` 和 `max_target_length` 来匹配你自己的数据集中的最大输入输出长度。并将模型路径 `THUDM/chatglm-6b` 改为你本地的模型路径。

如果你需要对验证集进行准确度评估，还需要对 `evaluate.sh` 进行相同的修改

`train.sh` 中的 `PRE_SEQ_LEN` 和 `LR` 分别是 soft prompt 长度和训练的学习率，可以进行调节以取得最佳的效果。我这里的学习率采用的是2e-2，相对来说是比较大的，可以避免找到局部最优解，但是会损失精度。

P-Tuning-v2 方法会冻结全部的模型参数，可通过调整 `quantization_bit` 来被原始模型的量化等级，不加此选项则为 FP16 精度加载。

在默认配置 `quantization_bit=4`、`per_device_train_batch_size=1`、`gradient_accumulation_steps=16` 下，INT4 的模型参数被冻结，一次训练迭代会以 1 的批处理大小进行 16 次累加的前后向传播，等效为 16 的总批处理大小，此时最低只需 6.7G 显存。若想在同等批处理大小下提升训练效率，可在二者乘积不变的情况下，加大 `per_device_train_batch_size` 的值，但也会带来更多的显存消耗，请根据实际情况酌情调整。

由于我的显存充足，所以我选择加大 `per_device_train_batch_size` 的值至16，同时降低 `gradient_accumulation_steps` 为1保持乘积，提高计算速度。此时我拿出的两块A10每块占用约14G显存。

`max_steps` 为训练的总步数， `save_steps` 为训练多少步保存一次检查点。经过多次实验，我发现模型在步数增大后会发生严重的遗忘现象，所以把Steps调低至200次，每25次保存一次。

`output_dir` 之后填写微调后模型的保存位置。

2.5 开始训练

一切配置完成后，执行bash train.sh 命令：

我的配置进行150步的训练只需要大概5-10分钟。

```
nsformers_modules.chatglm2-6b.modeling_chatglm - `use_cache=True` is incompatible with gradient checkpointing. Setting `use_cache=False`...
08/16/2023 08:52:03 - WARNING - transformers_modules.chatglm2-6b.modeling_chatglm - `use_cache=True` is incompatible with gradient checkpointing. Settin
g `use_cache=False`...
{'loss': 5.7582, 'learning_rate': 0.019, 'epoch': 0.01}
{'loss': 5.0518, 'learning_rate': 0.01800000000000002, 'epoch': 0.02}
{'loss': 4.9363, 'learning_rate': 0.017, 'epoch': 0.03}
{'loss': 5.0016, 'learning_rate': 0.016, 'epoch': 0.05}
{'loss': 4.9934, 'learning_rate': 0.015, 'epoch': 0.06}
 25%|                                                                                | 50/200 [02:00<05:59,  2.40s/it]Saving PrefixEncoder
```

训练完成后，打开文件夹就可以看到每个checkpoint和训练的具体参数。

/ ··· / output / adgen-chatglm2-6b-pt3-128-2e-3 /

Name	Last Modified
checkpoint-100	a day ago
checkpoint-125	a day ago
checkpoint-150	a day ago
checkpoint-25	a day ago
checkpoint-50	a day ago
checkpoint-75	a day ago
all_results.json	a day ago
train_results.json	a day ago
trainer_state.json	a day ago

```
▼ root:
    epoch: 2.68
    train_loss: 3.0548795572916667
    train_runtime: 450.6916
    train_samples: 1764
    train_samples_per_second: 10.65
    train_steps_per_second: 0.333
```

Epoch代表训练次数，可以看出我一共对训练集训练了2.68遍。误差为3.05。虽然这个误差没有降的很小，但是为了避免致命的过拟合，这样一个误差也能使我们相对安全地完成目标了。

2.6 模型推理

按照如下代码加载微调后的模型：

```
#原模型地址
path = "/home/ec2-user/SageMaker/chatglm2-6b"
tokenizer = AutoTokenizer.from_pretrained(path, trust_remote_code=True)
config = AutoConfig.from_pretrained(path, trust_remote_code=True, pre_seq_len=12
model = AutoModel.from_pretrained(path, trust_remote_code=True,config=config, de
#微调后的checkpoint地址
prefix_state_dict = torch.load(os.path.join("/home/ec2-user/SageMaker/chatglm2-6
new_prefix_state_dict = {}
for k, v in prefix_state_dict.items():
    if k.startswith("transformer.prefix_encoder."):
        new_prefix_state_dict[k[len("transformer.prefix_encoder."):]] = v
model.transformer.prefix_encoder.load_state_dict(new_prefix_state_dict)
model = model.cuda()
model = model.eval()
```

微调前后效果对比

原模型回答：

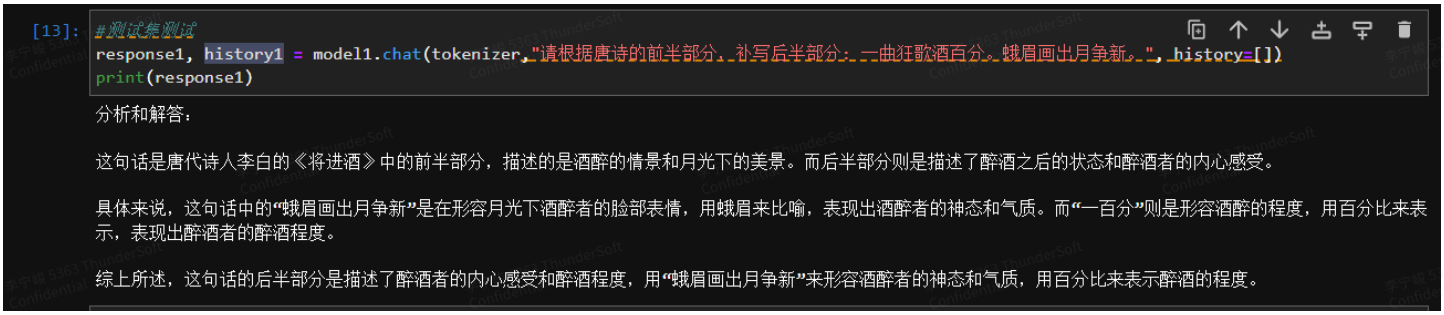

可以看到，原模型似乎会参考自己的训练材料，然后直接回答原文，但因为提问的古诗并不在它的训练材料里，所以它的回答明显是答非所问。

微调后模型回答：

微调后的模型在生成古诗的能力上有了很大的提升，它不再是从数据库中寻找，而是直接根据上文编写下文，尽管有些诗歌的生成效果可能不好，但是总体来看生成的诗句比较符合上文的意境，而且诗句能做到一些押韵。

美中不足的是，尽管已经做了很多措施来防止模型出现知识遗忘的现象，在面对训练集中没有出现的知识时，相对于原模型，微调后的模型的性能仍然会下降。